

## Redes Neurais Artificiais: conceitos e aplicações

Alexandre Zamberlan

Sistemas de Informação - UFN

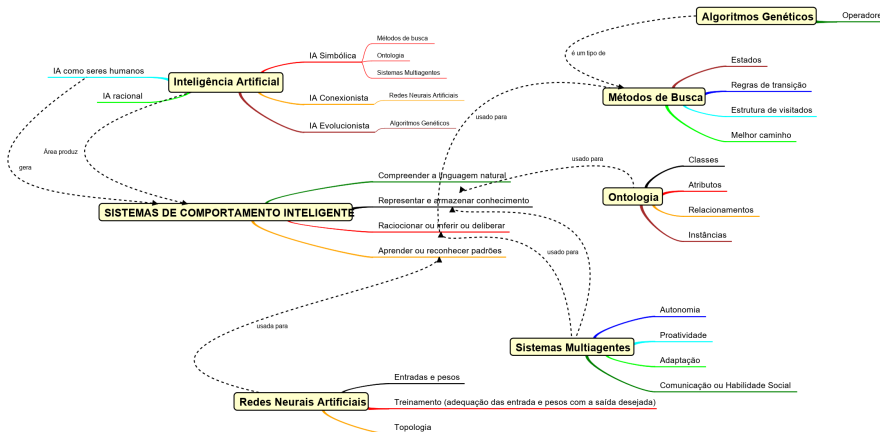
# Agenda

- 1 Inteligência Artificial
- 2 IA e suas aplicações
- 3 Sistemas de Comportamento Inteligente
- 4 Redes Neurais

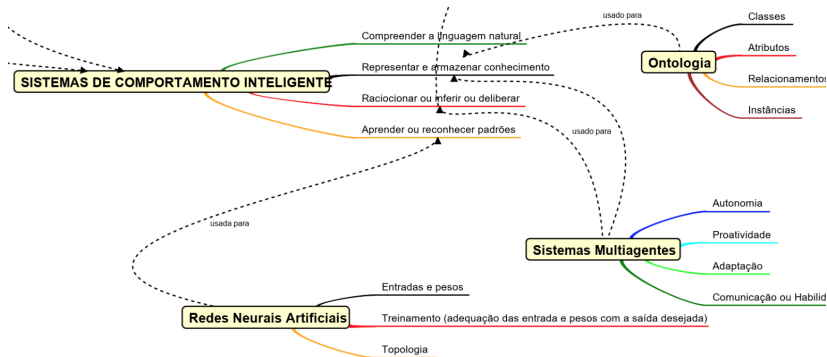
# Agenda

- 1 Inteligência Artificial
- 2 IA e suas aplicações
- 3 Sistemas de Comportamento Inteligente
- 4 Redes Neurais

# Mapa mental da área



# Mapa mental da área: RNA



# Agenda

- 1 Inteligência Artificial
- 2 IA e suas aplicações
- 3 Sistemas de Comportamento Inteligente
- 4 Redes Neurais

# Aplicações

- Problemas de 'empacotamento'
  - Não se sabe o estado final, muitas restrições, dificuldade de se visualizar os estados produzidos/visitados

# Aplicações

- Problemas de 'empacotamento'
  - Não se sabe o estado final, muitas restrições, dificuldade de se visualizar os estados produzidos/visitados
- Problemas de diagnóstico
  - Especialidade como diagnóstico médico, ...



# Aplicações

- Problemas de 'empacotamento'
  - Não se sabe o estado final, muitas restrições, dificuldade de se visualizar os estados produzidos/visitados
- Problemas de diagnóstico
  - Especialidade como diagnóstico médico, ...
- Problemas de autonomia
  - Veículos Autônomos Não Tripulados

# Aplicações

- Problemas de 'empacotamento'
  - Não se sabe o estado final, muitas restrições, dificuldade de se visualizar os estados produzidos/visitados
- Problemas de diagnóstico
  - Especialidade como diagnóstico médico, ...
- Problemas de autonomia
  - Veículos Autônomos Não Tripulados
- Problemas de Predição e Descoberta de Conhecimento
  - Previsões na bolsa de valores
  - Sistema de recomendação de produtos/serviços
  - Previsões Meteorológicas
  - Reconhecimento de objetos
  - ...

# Agenda

- 1 Inteligência Artificial
- 2 IA e suas aplicações
- 3 Sistemas de Comportamento Inteligente**
- 4 Redes Neurais

# Estrutura de Sistema de Comportamento Inteligente

- Base de Conhecimento
- Raciocínio Automatizado
- Aprendizado de Máquina

# Aprendizado de Máquina

- Reconhecimento de Padrões
  - textos, banco de dados, imagens, web, ..
- Treinamento
  - Dados de entrada do problema e seus pesos

# Aprendizado de Máquina

- Reconhecimento de Padrões
  - textos, banco de dados, imagens, web, ..
- Treinamento
  - Dados de entrada do problema e seus pesos

## Desafio I

Qual o próximo número? 2 10 12 16 17 18 19 ?

# Aprendizado de Máquina

- Reconhecimento de Padrões
  - textos, banco de dados, imagens, web, ..
- Treinamento
  - Dados de entrada do problema e seus pesos

## Desafio II

Qual a próxima letra? B C D G ?

# Aprendizado de Máquina

- Reconhecimento de Padrões
  - textos, banco de dados, imagens, web, ..
- Treinamento
  - Dados de entrada do problema e seus pesos

## Desafio


Q\_\_M N\_\_ CH\_R\_ N\_O M\_M\_!!



# Agenda

- 1 Inteligência Artificial
- 2 IA e suas aplicações
- 3 Sistemas de Comportamento Inteligente
- 4 Redes Neurais


# RNAs



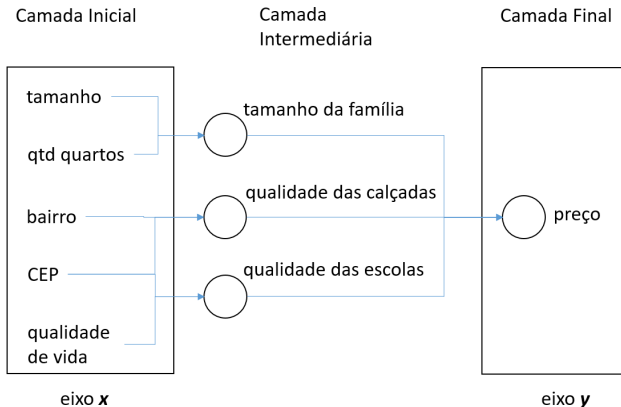
- Entradas ou atributos
- Pesos (importância dos atributos)
- Treinamento ou mecanismos de aprendizagem
  - treinar = aprender
  - supervisionado
  - não supervisionado
  - híbrido
- Arquitetura

# RNAs

## Problema imobiliário




# RNAs






X e Y são informados e a camada intermediária/oculta se ajusta

## RNA: definição

- processador massivamente paralelo que armazena conhecimento experimental
- modela o cérebro em dois aspectos
  - o conhecimento é adquirido pela rede por processo de aprendizagem/treinamento
  - as conexões entre neurônios são usadas para armazenar conhecimento



## RNA: funções de ativação



$$step_t(x) = \begin{cases} 1, & x \geq t \\ 0, & x < t \end{cases}$$

t = limiar

$$sigmoid(x) = \frac{1}{1 + e^{-x}}$$

$$sign(x) = \begin{cases} +1, & x \geq 0 \\ -1, & x < 0 \end{cases}$$

# RNAs: classificações

- Quanto ao tipo do algoritmo de aprendizagem
  - pesos fixos
  - supervisionado (treinamento por especialista)
  - não supervisionado
- Quanto à arquitetura
  - Feedforward (alimentação à frente)
  - Feedback (recorrente)
  - Multicamada

# RNAs: Tipos clássicos

- RNAs Recorrentes
  - Problema imobiliário: preços
  - Propagandas: online
  - Imagens: colocar tag em fotos
  - Áudio: reconhecimento de fala
  - Tradução
- RNAs Convolucionais
  - Vídeos: carros autônomos



# RNAs

INPUT (x)	OUTPUT (y)	APLICAÇÃO
propriedades da casa	Preço	Descobrir o verdadeiro preço
Propaganda mais informações de usuários	Predição se um usuário clicaria em um link	Propaganda online
imagem	objeto(1,.....,1000)	Tag foto
áudio	transcrição de texto	Reconhecimento de fala
português	inglês	Tradução automática
vídeo	posição de outros carros	Carros autônomos

X e Y são informados e a camada intermediária/oculta se ajusta

# RNA: aprender

- Aprender
  - incrementar o conhecimento
  - adaptar-se ao ambiente
- Como aprender?
  - observando
  - memorizando
  - generalizando
  - especializando

# RNA: algoritmo de aprendizagem

1. Obter o conjunto de amostras de treinamento  $\{x^{(k)}\}$
2. Associar o valor desejado  $\{d^{(k)}\}$  para cada amostra obtida
3. Iniciar o vetor de pesos  $\{w\}$  com valores aleatórios pequenos
4. Especificar a taxa de aprendizagem  $\{\eta\}$
5. Iniciar o contador de número de épocas (época = 0)
6. Repetir as seguintes instruções até que o erro de saída inexista:
  - 6.1 Inicializa erro (erro = "inexiste")
  - 6.2 Fazer o seguinte loop para todas as amostras de treinamento  $\{x^{(k)}, d^{(k)}\}$ :
    - 6.2.1  $u = w^T \cdot x^{(k)}$
    - 6.2.2  $y = g(u)$
    - 6.2.3 Se o erro existir (y diferente de  $d^{(k)}$ ):
      - 6.2.3.1  $w = w + \eta \cdot x^{(k)} \cdot (d^{(k)} - y)$
      - 6.2.3.2 Atualiza condição de erro (erro = "existe")
  - 6.3 Atualiza contador de épocas (época = época + 1)

# RNA: algoritmo para geração de novos valores

1. Obter o conjunto de amostras a serem classificadas
2. Carregar o vetor de pesos  $\{w\}$  ajustado no treinamento
3. Para cada amostra  $\{x\}$ :
  - 3.1  $u = w^T \cdot x$
  - 3.2  $y = g(u)$
  - 3.3 Verificar saída
    - 3.3.1 Se  $y = -1$ , amostra  $\{x\}$  pertence à {classe A}
    - 3.3.2 Se  $y = 1$ , amostra  $\{x\}$  pertence à {classe B}

Com isso, as novas amostras devem ser classificadas em uma das duas classes com base em classificações realizadas no período de treinamento.

## RNA: fases de projeto

- estudar o problema
- escolher uma arquitetura
  - número de entrada e saídas
  - número de camadas
  - recorrente ou não
- definir o algoritmo de aprendizagem
- construir (ou selecionar) o conjunto de treinamento
- realizar treinamento da rede
- testar

## Sugestões de leitura

- Wikipedia
  - [https://pt.wikipedia.org/wiki/Rede\\_neural\\_artificial](https://pt.wikipedia.org/wiki/Rede_neural_artificial)
- Livros
  - [Russell and Norvig 2016]

# Referências



Russell, S. J. and Norvig, P. (2016).  
*Artificial intelligence: a modern approach.*  
Malaysia; Pearson Education Limited,.